

UNIVERSIDAD EAFIT  
INGENIERÍA DE SISTEMAS  
TRAYECTORIA EN INGENIERÍA DE DATOS

---

# Documento de Definición del Proyecto y Entendimiento del Dominio

---

## FlightTracker

Plataforma DataOps para Monitoreo y Análisis Predictivo de Tráfico Aéreo

|                            |                                                                                          |
|----------------------------|------------------------------------------------------------------------------------------|
| <b>Asignatura:</b>         | SI4002 – Proyecto de Ingeniería de Datos                                                 |
| <b>Entregable:</b>         | Fase 1 (Sprint 0)                                                                        |
| <b>Profesor:</b>           | Edwin Montoya Múnera<br><a href="mailto:emontoya@eafit.edu.co">emontoya@eafit.edu.co</a> |
| <b>Semestre Académico:</b> | 2026-2                                                                                   |
| <b>Fecha de Entrega:</b>   | 29 de julio (Semana 3)                                                                   |

Medellín, Colombia

## Contents

|          |                                                                           |           |
|----------|---------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Información General del Proyecto y Equipo</b>                          | <b>2</b>  |
| 1.1      | Conformación del Equipo de Trabajo . . . . .                              | 2         |
| <b>2</b> | <b>Planteamiento del Problema y Contexto de Negocio</b>                   | <b>3</b>  |
| 2.1      | Contexto Organizacional y Descripción del Negocio . . . . .               | 3         |
| 2.2      | Situación Actual (AS-IS) vs. Estado Deseado (TO-BE) . . . . .             | 3         |
| 2.2.1    | Situación AS-IS (Diagnóstico Actual y Puntos de Dolor) . . . . .          | 3         |
| 2.2.2    | Estado TO-BE (Visión de la Solución) . . . . .                            | 4         |
| 2.3      | Matriz de Stakeholders e Interesados del Proyecto . . . . .               | 4         |
| <b>3</b> | <b>Formulación del Problema de Ingeniería de Datos</b>                    | <b>4</b>  |
| 3.1      | Objetivo General del Proyecto . . . . .                                   | 4         |
| 3.2      | Objetivos Específicos por Componente de la Trayectoria . . . . .          | 5         |
| 3.2.1    | Componente 1: Sistemas Intensivos en Datos (Big Data & DataOps) . . . . . | 5         |
| 3.2.2    | Componente 2: Bases de Datos Avanzadas . . . . .                          | 5         |
| 3.2.3    | Componente 3: Gestión y Gobernanza de Datos . . . . .                     | 5         |
| 3.3      | Preguntas de Negocio e Indicadores Clave de Desempeño (KPIs) . . . . .    | 5         |
| 3.4      | Alcance y Restricciones del Proyecto . . . . .                            | 6         |
| <b>4</b> | <b>Metodología de Desarrollo y Cronograma</b>                             | <b>7</b>  |
| 4.1      | Marcos de Referencia . . . . .                                            | 7         |
| 4.2      | Fases del Proyecto . . . . .                                              | 8         |
| <b>5</b> | <b>Cronograma de Sprints, Entregables y Gestión de Riesgos</b>            | <b>9</b>  |
| 5.1      | Planificación de Entregas por Sprints . . . . .                           | 9         |
| 5.2      | Matriz Inicial de Riesgos del Proyecto . . . . .                          | 10        |
| <b>6</b> | <b>Criterios de Evaluación y Rúbrica de la Fase 1</b>                     | <b>11</b> |

*“Este documento no es solo un requisito académico, sino el contrato técnico y estratégico del proyecto de Ingeniería de Datos con el curso, el profesor y la evaluación.”*

## 1. Información General del Proyecto y Equipo

| Campo                     | Información                                                                                                                                                                                                                                                                        |
|---------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Nombre del Proyecto       | Plataforma DataOps para Monitoreo y Análisis Predictivo de Tráfico Aéreo (FlightTracker)                                                                                                                                                                                           |
| Empresa / Caso de Estudio | Caso de estudio basado en el sector de la aviación comercial, utilizando fuentes de datos públicas y abiertas (BTS, OpenSky Network, OpenFlights). El proyecto se enfoca en los desafíos reales de la industria, como la optimización de la puntualidad y la eficiencia operativa. |
| Semestre Académico        | 2026-2                                                                                                                                                                                                                                                                             |
| Fecha de Entrega          | 29 de julio (Semana 3)                                                                                                                                                                                                                                                             |

Table 1: Información general del proyecto

### 1.1 Conformación del Equipo de Trabajo

| Nombre                                                                                                                                                                     | Correo EAFIT            | Correo Gmail                | Rol Principal                       |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------|-----------------------------|-------------------------------------|
| Agustín Figueroa Sierra                                                                                                                                                    | afigueroas@eafit.edu.co | figuesicsi@gmail.com        | Arquitecto de Datos / Líder Técnico |
| <i>Responsabilidades:</i> Definición de la arquitectura de referencia, selección de tecnologías, coordinación del equipo y supervisión de la integración de componentes.   |                         |                             |                                     |
| Gabriela Lucía Martínez Mercado                                                                                                                                            | glmartinem@eafit.edu.co | gabymartinez12319@gmail.com | Ingeniero de Datos – Streaming      |
| <i>Responsabilidades:</i> Implementación de la ingesta y procesamiento en tiempo real, incluyendo la configuración de Kafka y el desarrollo de los pipelines de streaming. |                         |                             |                                     |
| Juan Carlos Muñoz Trejos                                                                                                                                                   | jcmunozt@eafit.edu.co   | jcarlosmt00@gmail.com       | Ingeniero de Datos – Batch          |
| <i>Responsabilidades:</i> Implementación de la ingesta y procesamiento batch, incluyendo la orquestación con Airflow y el desarrollo de los pipelines de transformación.   |                         |                             |                                     |

| Nombre                                                                                                                                                                | Correo EAFIT               | Correo Gmail                | Rol Principal                             |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------|-----------------------------|-------------------------------------------|
| Juan Simón<br>Ospina Martínez                                                                                                                                         | jsospinam@eafit.e<br>du.co | juansimonreal@gm<br>ail.com | Responsable de<br>Gobernanza y<br>Calidad |
| <i>Responsabilidades:</i> Implementación del catálogo de datos, definición de reglas de calidad, documentación del linaje y aseguramiento del cumplimiento normativo. |                            |                             |                                           |

Table 2: Equipo de trabajo del proyecto

## 2. Planteamiento del Problema y Contexto de Negocio

### 2.1 Contexto Organizacional y Descripción del Negocio

La industria de la aviación comercial enfrenta pérdidas anuales significativas debido a retrasos y cancelaciones de vuelos, que generan costos operativos adicionales en combustible, tripulación y mantenimiento, además de afectar la experiencia del pasajero y la eficiencia aeroportuaria.

Las estadísticas reflejan la magnitud del problema. Según el Buró de Estadísticas de Transporte de EE.UU. (BTS), en 2024 se retrasaron 1,531,080 vuelos domésticos, equivalentes al 20.3% del total programado, mientras que las cancelaciones alcanzaron las 102,908. A nivel global, se cancelan aproximadamente 2,100 vuelos diarios, cerca del 3% de todas las salidas. El impacto económico es considerable: la Asociación de Transporte Aéreo Internacional (IATA) estima que los problemas en la cadena de suministro de la industria costarán más de 11 mil millones de dólares en 2025, derivados del exceso de combustible, mantenimiento adicional y arrendamiento de motores. Adicionalmente, las compensaciones a pasajeros por retrasos representan un costo anual de casi 10 mil millones de euros solo en Europa.

Ante este panorama, la modernización de la infraestructura de datos y análisis se ha convertido en una necesidad estratégica para el sector. La capacidad de anticipar retrasos, optimizar la asignación de recursos y comunicar información precisa no solo mejora la eficiencia operativa, sino que también reduce costos y fortalece la competitividad en un entorno cada vez más desafiante. El manejo eficiente de los datos es hoy un factor crítico para la supervivencia y el crecimiento en la aviación comercial.

### 2.2 Situación Actual (AS-IS) vs. Estado Deseado (TO-BE)

#### 2.2.1 Situación AS-IS (Diagnóstico Actual y Puntos de Dolor)

Actualmente, el sector de la aviación comercial enfrenta una fragmentación de fuentes de datos que dificulta una visión integral de la operación. Las aerolíneas, aeropuertos y autoridades de control aéreo manejan sistemas dispares que no se comunican entre sí, lo que genera silos de información. Los procesos de análisis y generación de reportes son mayoritariamente batch y manuales, con latencias de hasta 24 horas, impidiendo la toma de decisiones en tiempo real. La calidad de los datos es inconsistente, con valores nulos, duplicados y errores en campos críticos como horarios y causas de retraso. No existen mecanismos estandarizados de gobernanza que aseguren la trazabilidad y el linaje de los datos, lo que complica la auditoría y el cumplimiento regulatorio.

### 2.2.2 Estado TO-BE (Visión de la Solución)

El proyecto propone una plataforma analítica desacoplada, elástica y desplegada en la nube, capaz de ingerir datos de tráfico aéreo en tiempo real desde fuentes públicas (OpenSky Network) y datos históricos masivos desde repositorios oficiales (BTS). La solución integrará un Data Lakehouse con zonas Bronze (datos crudos), Silver (datos depurados y validados) y Gold (datos modelados en estrella para análisis). Los pipelines de procesamiento (batch y streaming) se orquestrarán mediante Apache Airflow y se ejecutarán en Apache Spark, garantizando escalabilidad y tolerancia a fallos. Un catálogo de datos, reglas de calidad automatizadas y un linaje documentado asegurarán la gobernanza y la confianza en la información. Los resultados se consumirán a través de un dashboard ejecutivo en Power BI, un mapa interactivo de vuelos en tiempo real y una API REST para consultas operacionales. Con esto, el sector dispondrá de información confiable y oportuna para reducir retrasos, optimizar recursos y mejorar la experiencia del pasajero.

## 2.3 Matriz de Stakeholders e Interesados del Proyecto

| Stakeholder / Rol                 | Tipo de Perfil       | Expectativa Principal                                                    | Valor Esperado / Uso del Producto                                              |
|-----------------------------------|----------------------|--------------------------------------------------------------------------|--------------------------------------------------------------------------------|
| Autoridades de Aviación Civil     | Gobierno / Regulador | Visión consolidada del tráfico aéreo para la planificación y regulación. | Mejora en la supervisión, cumplimiento normativo y planificación de rutas.     |
| Aerolíneas                        | Negocio / Operativo  | Datos en tiempo real sobre el estado de sus vuelos y flota.              | Reducción de retrasos, optimización de combustible y mejora de la puntualidad. |
| Operadores Aeroportuarios         | Negocio / Operativo  | Información sobre la ocupación de puertas, demoras y flujo de pasajeros. | Optimización de la asignación de recursos y mejora de la eficiencia operativa. |
| Pasajeros                         | Usuario Final        | Información precisa y actualizada sobre el estado de los vuelos.         | Mejora de la experiencia de viaje y reducción de incertidumbre.                |
| Ingenieros de Datos / Arquitectos | Técnico              | Pipelines escalables, modulares y con monitoreo continuo.                | Mantenimiento eficiente de la plataforma y capacidad de evolución tecnológica. |

Table 3: Matriz de stakeholders

## 3. Formulación del Problema de Ingeniería de Datos

### 3.1 Objetivo General del Proyecto

Diseñar, implementar y desplegar una arquitectura distribuida de ingeniería de datos en la nube que integre ingesta escalable en tiempo real (streaming) y procesamiento masivo de datos históricos (batch), sobre un Data Lakehouse gobernado, para proporcionar una plataforma unificada de monitoreo y análisis predictivo de tráfico aéreo. La solución deberá garantizar baja latencia en las

alertas, alto rendimiento en consultas analíticas, y un marco de gobernanza que asegure la calidad, trazabilidad y cumplimiento normativo de los datos, aplicable a los diferentes actores del sector de la aviación.

## 3.2 Objetivos Específicos por Componente de la Trayectoria

### 3.2.1 Componente 1: Sistemas Intensivos en Datos (Big Data & DataOps)

Diseñar e implementar pipelines resilientes y escalables para la ingesta y procesamiento de datos, combinando procesamiento batch (Apache Spark sobre datos históricos del BTS) y streaming (Spark Structured Streaming sobre datos de OpenSky Network). Orquestar los flujos de trabajo con Apache Airflow y automatizar el ciclo de vida de la infraestructura mediante prácticas de DataOps (CI/CD con GitHub Actions, contenerización con Docker). Se deberá garantizar una latencia de extremo a extremo inferior a 1 minuto para las alertas en tiempo real y un rendimiento de procesamiento batch que permita la actualización diaria del modelo analítico con millones de registros.

### 3.2.2 Componente 2: Bases de Datos Avanzadas

Modelar, estructurar y optimizar las capas de almacenamiento del Data Lakehouse, utilizando Delta Lake como formato de tabla transaccional. Diseñar un modelo en estrella para la zona Gold que incluya tablas de hechos (vuelos) y dimensiones (fechas, aerolíneas, aeropuertos, causas de retraso). Justificar el diseño físico mediante estrategias de particionamiento (por año y mes), indexación (Z-order en columnas de fecha y aerolínea) y compresión, utilizando herramientas como **EXPLAIN** y **ANALYZE** para afinar el rendimiento de las consultas. Considerar los compromisos del Teorema CAP al seleccionar la consistencia y disponibilidad para el Serving Layer.

### 3.2.3 Componente 3: Gestión y Gobernanza de Datos

Implementar un programa funcional de gobierno del dato basado en el marco DAMA-DMBOK. Esto incluye la creación de un catálogo de datos automatizado (OpenMetadata), la definición de un glosario/diccionario de datos, el rastreo de linaje (OpenLineage) desde las fuentes hasta los dashboards, la ejecución de pruebas de calidad (Great Expectations) con reglas como completitud (>98%), unicidad (100%) y rangos válidos para métricas de retraso, y la aplicación de políticas de privacidad para el manejo de datos sensibles (anonimización de identificadores de aeronaves y enmascaramiento de coordenadas en caso de ser necesario). Se deberá documentar la Matriz RACI de los activos de datos.

## 3.3 Preguntas de Negocio e Indicadores Clave de Desempeño (KPIs)

| Pregunta de Negocio                                                                | KPI / Indicador                                 | Métrica Técnica / SLA                                                                 | Componente               |
|------------------------------------------------------------------------------------|-------------------------------------------------|---------------------------------------------------------------------------------------|--------------------------|
| ¿Cuál es el porcentaje de llegadas a tiempo por aerolínea y ruta en el último mes? | Puntualidad por aerolínea (On-Time Performance) | Tiempo de respuesta de consulta en la zona Gold < 500 ms para agregaciones mensuales. | Bases de Datos Avanzadas |

| Pregunta de Negocio                                                                              | KPI / Indicador                      | Métrica Técnica / SLA                                                                                                 | Componente                      |
|--------------------------------------------------------------------------------------------------|--------------------------------------|-----------------------------------------------------------------------------------------------------------------------|---------------------------------|
| ¿Cuáles son las principales causas de retraso y cómo varían por hora del día y día de la semana? | Distribución de causas de retraso    | Disponibilidad de datos históricos actualizados diariamente con latencia de $< 2$ horas desde la publicación del BTS. | Batch / DataOps                 |
| ¿Qué vuelos presentan un alto riesgo de retraso en las próximas 2 horas?                         | Alertas tempranas de retraso         | Latencia de detección $< 60$ segundos desde la recepción del evento hasta la generación de la alerta.                 | Sistemas Intensivos (Streaming) |
| ¿Se mantiene la calidad y consistencia de los datos a lo largo del tiempo?                       | Score de Calidad de Datos (DQ Score) | Complejidad $> 98\%$ , Unicidad $100\%$ , Validez de rangos (ej. retraso $\geq 0$ ) en las capas Silver y Gold.       | Gobernanza de Datos             |
| ¿Cuántos vuelos activos hay en cada región y cuál es su estado operacional?                      | Volumen de vuelos en tiempo real     | Throughput de ingesta de eventos desde OpenSky $\geq 1000$ eventos/segundo.                                           | Sistemas Intensivos (Streaming) |

Table 4: Preguntas de negocio y KPIs

### 3.4 Alcance y Restricciones del Proyecto

#### Qué SÍ incluye el proyecto

- Diseño de la arquitectura de referencia (Lambda + Data Lakehouse) y provisión de servicios en la nube pública (AWS o GCP).
- Ingesta automatizada desde al menos 3 fuentes heterogéneas: OpenSky API (streaming), BTS (batch) y OpenFlights (maestro).
- Procesamiento distribuido masivo tanto batch (Spark) como streaming (Spark Structured Streaming).
- Modelado analítico en estrella (zona Gold) y optimización de consultas con índices y particionamiento.
- Implementación de gobernanza: catálogo de datos, diccionario, reglas de calidad, linaje y políticas de privacidad.
- Exposición de los datos gobernados a través de un dashboard ejecutivo, un mapa interactivo de vuelos y una API REST.

## Qué NO incluye el proyecto

- Entrenamiento de modelos de Machine Learning supervisados o no supervisados para predicción de retrasos (se considera un componente opcional y fuera del alcance principal).
- Desarrollo de una aplicación frontend compleja o sistema de gestión de pasajeros.
- Integración con sistemas internos de aerolíneas o aeropuertos (por restricciones de acceso a datos propietarios).

## Restricciones Técnicas, Organizacionales y Éticas

- **Presupuesto Cloud:** el desarrollo está limitado a los créditos educativos proporcionados (AWS Educate o GCP for Education). Se requiere un uso eficiente de los recursos, incluyendo el apagado automático de clústeres cuando no se utilicen y la monitorización continua de costos.
- **Recomendación del Docente:** se sugiere adoptar una nube pública con servicios gestionados que simplifiquen la orquestación (por ejemplo, AWS con MWAA, MSK y EMR, o GCP con Composer, Pub/Sub y Dataproc). Es altamente recomendable incluir un flujo de datos en streaming para demostrar capacidades de procesamiento en tiempo real.
- **Restricciones Éticas / Legales:** los datos utilizados son públicos y no contienen información personal identificable (PII). No obstante, se aplicarán principios de transparencia y responsabilidad en el manejo de la información, y se documentarán las políticas de acceso y uso de datos. En caso de que se generen datos sintéticos, se asegurará que no estén basados en información sensible real.

# 4. Metodología de Desarrollo y Cronograma

## 4.1 Marcos de Referencia

- **CRISP-DM / TDSP:** se utilizará en las primeras fases para comprender el dominio del problema de negocio, perfilar las fuentes de datos y garantizar que el modelado tenga un propósito analítico claro. El entendimiento del negocio y de los datos guiará la definición de KPIs y la selección de fuentes.
- **DataOps:** fundamental para evitar que el proyecto sea un código de un solo uso. Se aplicará para garantizar la entrega continua, la orquestación automatizada, el control de versiones (Git), la integración continua (CI/CD) y la observabilidad de los pipelines mediante monitoreo y logging.
- **Agile / Scrum:** proveerá la cadencia de trabajo del equipo. El desarrollo se dividirá en sprints de 3-4 semanas (Sprint 0 a Sprint Final) con entregables demostrables al final de cada ciclo, facilitando la adaptación ante bloqueos técnicos y cambios en los requisitos.
- **DAMA-DMBOK:** actuará como el pilar de confianza para la gobernanza. Asegurará que la solución contemple desde el día 1 aspectos como la gestión de metadatos, calidad de datos, linaje, seguridad y cumplimiento regulatorio.



## 4.2 Fases del Proyecto

| Fase de la Metodología                  | Actividades Principales                                                                                                                                                                                                                                                                                                                                                    | Marco / Disciplina Dominante |
|-----------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------|
| Fase 1. Problema y Dominio              | 1.1 Levantamiento de requerimientos y definición de KPIs de negocio. 1.2 Identificación de stakeholders y matriz de interesados. 1.3 Definición del alcance y restricciones. 1.4 Elaboración de la propuesta de proyecto (este documento).                                                                                                                                 | CRISP-DM / Agile             |
| Fase 2. Datos del Proyecto              | 2.1 Identificación de fuentes de datos (OpenSky, BTS, OpenFlights). 2.2 Adquisición y/o simulación de datos. 2.3 Carga preliminar en el Data Lake (zona Bronze). 2.4 Análisis exploratorio y perfilamiento (data profiling) con herramientas como Great Expectations (detección de nulos, duplicados, distribuciones, calidad).                                            | Bases de Datos Avanzadas     |
| Fase 3. Diseño de Arquitectura de Datos | 3.1 Selección de la arquitectura de referencia (Lambda + Data Lakehouse). 3.2 Elección del proveedor de nube (AWS o GCP) y servicios específicos. 3.3 Diseño lógico y físico de la topología de red, flujos de ingesta (batch vs streaming), y componentes de almacenamiento y procesamiento.                                                                              | Sistemas Intensivos en Datos |
| Fase 4. Modelado de Datos               | 4.1 Diseño de esquemas transaccionales (tablas maestras) y analíticos (modelo en estrella para la zona Gold). 4.2 Definición de particionamiento, índices (Z-order), estrategias de compresión y optimización física. 4.3 Modelado de datos NoSQL para la capa de serving (API).                                                                                           | BD Avanzadas / Modelado      |
| Fase 5. Ingeniería de Pipelines         | 5.1 Construcción de DAGs en Airflow para la ingesta y transformación batch. 5.2 Desarrollo de scripts de ingesta streaming (productor Kafka) y procesamiento con Spark Structured Streaming. 5.3 Implementación de transformaciones (limpieza, enriquecimiento, integración) usando Spark y dbt para la capa Gold. 5.4 Procesamiento transaccional para la API de consumo. | DataOps / Big Data           |

| Fase de la Metodología          | Actividades Principales                                                                                                                                                                                                                                                | Marco / Disciplina Dominante |
|---------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------|
| Fase 6. Calidad y Gobernanza    | 6.1 Despliegue de herramientas de catálogo (OpenMetadata) y linaje (OpenLineage). 6.2 Implementación de reglas de calidad con Great Expectations, ejecutadas en los pipelines. 6.3 Documentación del diccionario de datos, políticas de acceso y matriz RACI.          | DAMA-DMBOK / Gestión         |
| Fase 7. CI/CD y Despliegue      | 7.1 Creación de workflows de integración continua (GitHub Actions) para pruebas unitarias y de datos. 7.2 Contenerización de los componentes (Docker) y automatización del despliegue en la nube. 7.3 Configuración de entornos de desarrollo, pruebas y producción.   | DataOps / DevOps             |
| Fase 8. Observabilidad y Mejora | 8.1 Configuración de tableros de monitoreo (Prometheus + Grafana) para pipelines y servicios. 8.2 Establecimiento de alertas por fallos y degradación de rendimiento. 8.3 Análisis de costos en la nube y optimización de recursos (auto-scaling, apagado programado). | DataOps / Operación IT       |

Table 5: Fases del proyecto

## 5. Cronograma de Sprints, Entregables y Gestión de Riesgos

### 5.1 Planificación de Entregas por Sprints

| Sprint   | Semanas de Ejecución | Fecha Clave / Peso | Entregables e Hitos Principales                                                                                                                                                                        |
|----------|----------------------|--------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Sprint 0 | Semanas 1 a 3        | 29 de Julio (10%)  | Documento de Propuesta de Proyecto (este documento), Canvas del proyecto, Arquitectura Conceptual, definición de KPIs de negocio, identificación de fuentes de datos y plan de adquisición/simulación. |

| Sprint       | Semanas de Ejecución | Fecha Clave / Peso    | Entregables e Hitos Principales                                                                                                                                                                                                                                   |
|--------------|----------------------|-----------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Sprint 1     | Semanas 4 a 7        | 26 de Agosto (30%)    | Producto Alfa (Walking Skeleton): Infraestructura cloud aprovisionada, scripts de ingesta funcional (conexión a OpenSky y descarga de BTS), almacenamiento en capa Bronze, perfilamiento de datos con Great Expectations y reglas de calidad básicas operando.    |
| Sprint 2     | Semanas 8 a 15       | 28 de Octubre (30%)   | Producto Beta (Escalabilidad y Gobierno): Pipelines ETL/ELT completos (batch y streaming), modelo en estrella en la zona Gold con optimizaciones (índices, particionamiento), catálogo de datos poblado, linaje activo, y primeras versiones del dashboard y API. |
| Sprint Final | Semanas 16 a 17      | 11 de Noviembre (30%) | Producto Final (Operación y Consumo): Prácticas DataOps automatizadas (CI/CD), monitoreo y alertas activas, dashboard final, API REST documentada, informe técnico completo y sustentación ejecutiva.                                                             |

Table 6: Planificación de entregas por sprint

## 5.2 Matriz Inicial de Riesgos del Proyecto

| Riesgo Identificado                                                                             | Área de Impacto             | Impacto / Prob. | Estrategia de Mitigación y Plan de Contingencia                                                                                                                                                                                                      | Responsable                         |
|-------------------------------------------------------------------------------------------------|-----------------------------|-----------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------|
| Disponibilidad limitada de los servicios académicos en la nube (cuotas, créditos insuficientes) | Infraestructura / Económico | Alto / Medio    | Establecer cuotas diarias de gasto en el billing de la nube. Automatizar el apagado de clústeres costosos (Spark, Kafka) mediante scripts al terminar las pruebas diarias. Utilizar capas gratuitas para servicios serverless (ej. Cloud Functions). | Arquitecto de Datos / Líder Técnico |

| Riesgo Identificado                                                                      | Área de Impacto     | Impacto / Prob. | Estrategia de Mitigación y Plan de Contingencia                                                                                                                                                                                                             | Responsable                         |
|------------------------------------------------------------------------------------------|---------------------|-----------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------|
| Dificultad para obtener datos reales de todas las fuentes (especialmente BTS por tamaño) | Datos               | Alto / Medio    | El equipo identificará claramente las fuentes y, en caso de que la descarga masiva no sea viable, generará datos sintéticos que simulen el comportamiento real de las fuentes, garantizando volumen y variedad suficientes para demostrar la escalabilidad. | Líder Técnico / Ingeniero Batch     |
| Fallas técnicas, intermitencia o inaccesibilidad de las APIs originales (OpenSky)        | Datos / Flujo       | Alto / Bajo     | Crear y almacenar localmente un dataset simulado robusto o un generador en Python que inyecte eventos continuos simulando el comportamiento real de la API (posiciones, velocidades, etc.). Implementar mecanismos de reintentos y caché en el productor.   | Ingeniero de Streaming              |
| Mala calidad de los datos detectada tardíamente (ej. valores nulos en campos críticos)   | Analítica / Calidad | Medio / Alto    | Adelantar el Data Profiling agresivamente en el Sprint 1. Implementar reglas de descarte automático para registros que no cumplan los esquemas críticos y generar alertas tempranas.                                                                        | Responsable de Gobernanza y Calidad |
| Abandono de la materia o inasistencia reiterada de un integrante clave                   | Gestión / Equipo    | Alto / Bajo     | Aplicación estricta del pacto pedagógico. Documentación exhaustiva en Git y asignación de responsabilidades redundantes para que cualquier rol pueda ser asumido temporalmente por otro compañero.                                                          | Líder Técnico                       |

Table 7: Matriz inicial de riesgos

*Nota: Este documento constituye la propuesta formal del proyecto FlightTracker para el Sprint 0. Una vez aprobado, servirá como guía para el desarrollo de los sprints posteriores. El equipo se compromete a actualizarlo y refinarlo conforme avance el proyecto, manteniendo la comunicación continua con el profesor.*